# MapReduce com Imagens Utilizando a Biblioteca HIPI Para Cálculo de PCA

Projeto 1 - Grupo 5

# **Grupo 5 - Integrantes**

Lucas Alves Racoci 156331


Luiz Fernando Rodrigues da Fonseca 156475

Rafael Zane 157079


Rodrigo Noronha Máximo 157209

# HIPI - Hadoop Image Processing Interface

- Biblioteca de processamento de imagens
- Utilizada com o Hadoop
- Armazenar uma grande coleção de imagens no HDFS
- Integração com o OpenCV
- Tipos diferentes de dados na entrada
- HIB HIPI Image Bundle
- Documentação e instalação através do link:
   <a href="http://hipi.cs.virginia.edu/index.html">http://hipi.cs.virginia.edu/index.html</a>
- Utilização de Gradle para compilar código Java e o HIPI



#### Workflow do HIPI




# **HIPI - Hadoop Image Processing Interface**

 Ferramentas para transformar um conjunto de imagens em um arquivo do tipo HIPI que serve de entrada para os processos de MapReduce que envolvem o HIPI, e o resultado já é gravado no HDFS:

\$ tools/hibImport.sh ~/SampleImages sampleimages.hib






# HIPI - Hadoop Image Processing Interface


• Também existe uma ferramenta para acessar o HDFS e ver as informações de arquivos HIB:

\$ tools/hibInfo.sh sampleimages.hib --show-meta

```
Input HIB: sampleimages.hib
Display meta data: true
Display EXIF data: false
IMAGE INDEX: 0
512 x 512
format: 2
meta: {filename=baboon.png, source=../SampleImages/baboon.png}
IMAGE INDEX: 1
512 x 512
format: 2
meta: {filename=peppers.png, source=../SampleImages/peppers.png}
Found [2] images.
```



# Workflow do primeiro teste



#### Primeiro Teste - Média de Pixels

#### Configuração:

- Formato de input
- Classe Mapper
- Classe Reducer
- Tipo do par chave, valor
- Caminho para os arquivos de entrada e saída no HDFS
- http://hipi.cs.virginia.
   edu/gettingstarted.h
   tml

```
Job job = Job.getInstance();
job.setInputFormatClass(HibInputFormat.class);
job.setJarByClass(HelloWorld.class);
job.setMapperClass(HelloWorldMapper.class);
job.setReducerClass(HelloWorldReducer.class);
job.setMapOutputKeyClass(IntWritable.class);
job.setMapOutputValueClass(FloatImage.class);
job.setOutputKeyClass(IntWritable.class);
job.setOutputValueClass(Text.class);
FileInputFormat.setInputPaths(job, new Path(args[0]));
FileOutputFormat.setOutputPath(job, new Path(args[1]));
boolean success = job.waitForCompletion(true);
```

## **Mapper**

- Cria um vetor com o valor médio de vermelho, verde e azul
- Percorre a matriz da imagem obtendo os valores de cada cor para cada pixel
- Cria uma imagem (vetor com três posições) com a soma dos valores de cada cor e divide pela quantidade total de pixels
- Salva no contexto do hipi a chave 1 com o valor sendo a imagem

```
float[] valData = value.getData();
float[] avgData = {0,0,0};
for (int j = 0; j < h; j++) {
  for (int i = 0; i < w; i++) {
    avgData[0] += valData[(j*w+i)*3+0]; // R
   avgData[1] += valData[(j*w+i)*3+1]; // G
   avgData[2] += valData[(i*w+i)*3+2]; // B
FloatImage avg = new FloatImage(1, 1, 3, avgData);
avg.scale(1.0f/(float)(w*h));
context.write(new IntWritable(1), avg);
```

#### Reducer

- Cria a imagem que conterá a saída
- Soma os valores recebidos dos mappers
- Obtém uma nova média
- Imprime o
   resultado e coloca
   o par chave e valor
   que será escrito
   no HDFS


```
FloatImage avg = new FloatImage(1, 1, 3);
int total = 0;
for (FloatImage val : values) {
  avg.add(val);
  total++;
if (total > 0) {
  avg.scale(1.0f / total);
     float[] avgData = avg.getData();
  String result = String.format("Average pixel value: %f %f %f", avgData[0], avgData[1], avgData[2]);
  context.write(key, new Text(result));
```

Para rodar o código e ver o resultado:

\$ hadoop jar build/libs/helloWorld.jar sampleimages.hib sampleimages\_average

\$ hdfs dfs -cat sampleimages\_average/part-r-00000


1 Average pixel value: 0,279852 0,260834 0,220869





Average pixel value: 0,424189 0,387541

0,295646









Average pixel value: 0,155569 0,302869

0,366745












Average pixel value: 0,279852 0,260834

0,220869

real 0m8.786s user 0m8.498s sys 0m4.098s



# **OpenCV**

- Open Source
- Biblioteca de visão computacional e machine learning em C++
- Cerca de 2500 algoritmos otimizados
- Interfaces em C++, C, Python, Java e MATLAB



# Segundo Teste - Matriz de Covariância (PCA)

$$\Sigma = \mathbf{E} \left[ (\mathbf{X} - \mathbf{E}[\mathbf{X}]) (\mathbf{X} - \mathbf{E}[\mathbf{X}])^{\mathrm{T}} \right]$$

$$= \frac{1}{n} \sum_{i}^{n} (x_{i} - \bar{x})(x_{i} - \bar{x})^{T} = \frac{1}{n} \hat{X} \hat{X}^{T}$$

$$= \begin{pmatrix} \begin{vmatrix} & & | \\ \hat{x_{i}} & \dots & \hat{x_{n}} \\ | & | \end{pmatrix} \begin{pmatrix} - & \hat{x_{1}} & - \\ \vdots & & \\ - & \hat{x_{n}} & - \end{pmatrix}$$


$$= \begin{pmatrix} A & B \end{pmatrix} \begin{pmatrix} A \\ B \end{pmatrix}$$

$$= AA^{T} + BB^{T}$$

- Objetivo: Obter informações estatísticas de segunda ordem entre recortes de 64x64 pixels de imagens naturais.
- Os autovetores de maior autovalor da matriz têm uma utilidade tão grande em outras áreas de Data Analysis que são chamados de Componentes principais, daí o nome PCA (Principal Component Analysis)


#### Fontes:

- http://hipi.cs.virginia.edu/examples/pca.html
- The Principal Components of Natural Images by Hancock




**Primeiro MapReduce** Map Reduce Average Patch

# Segundo Map




# **Segundo Reduce**



A imagem ao lado mostra as 15 primeiras componentes principais (autovetores) da matriz de covariância

Tempo de execução:

real 0m34.810s user 0m36.481s sys 0m5.959s



-0.075

-0.025

-0.050

-0.075


#### **Terceiro Teste - Borramento**

#### Configuração:

- Tipo dos pares chave, valor
- OpenCV
- Saída binária
- hashCode do Java para diferenciar as imagens

```
// Initialize and configure MapReduce job
Job job = Job getInstance();
// Set input format class which parses the input HIB and spawns map tasks
job setInputFormatClass(HibInputFormat class);
// Set the driver, mapper, and reducer classes which express the computation
job.setJarByClass(Gaussiana.class);
job_setMapperClass(GaussianaMapper_class);
iob.setReducerClass(GaussianaReducer.class);
// Set the types for the key/value pairs passed to/from map and reduce layers
job_setMapOutputKeyClass(IntWritable_class);
job setMapOutputValueClass(OpenCVMatWritable class);
job_setOutputKeyClass(NullWritable_class);
job.setOutputValueClass(OpenCVMatWritable.class);
job setOutputFormatClass(BinaryOutputFormat class);
// Set the input and output paths on the HDFS
FileInputFormat.setInputPaths(job, new Path(args[0]));
FileOutputFormat.setOutputPath(job, new Path(args[1]));
// Execute the MapReduce job and block until it complets
boolean success = job.waitForCompletion(true);
```

# **MapReduce**



# **MapReduce**

```
ublic static final int sizeX = 5;
public static final int sizeY = 5;
oublic static class GaussianaMapper extends Mapper<HipiImageHeader, FloatImage, IntWritable, OpenCVMatWritable> {
  public void map(HipiImageHeader key, FloatImage image, Context context)
     throws IOException, InterruptedException {
   Mat cvImageRGB = OpenCVUtils.convertRasterImageToMat(image);
   Mat cvGaussianRGB = new Mat();
   opencv_imgproc.blur(cvImageRGB, cvGaussianRGB, new Size(sizeX, sizeY));
   context.write(new IntWritable(cvGaussianRGB.hashCode()), new OpenCVMatWritable(cvGaussianRGB));
 } // map()
} // GaussianaMapper
public static class GaussianaReducer extends Reducer<IntWritable, OpenCVMatWritable, NullWritable, OpenCVMatWritable> {
  public void reduce(IntWritable key, Iterable<OpenCVMatWritable> values, Context context)
     throws IOException, InterruptedException {
    for (OpenCVMatWritable value : values) {
     context.write(NullWritable.get(), value);
  } // reduce()
```

# **Terceiro MapReduce**

Map Reduce









#### Conclusão

- HIPI é um framework muito poderoso e robusto para se integrar o processamento de imagens com o sistema do Hadoop
- Isso inclui as ferramentas de conversão de imagens para o formato HIB disponíveis e as bibliotecas integradas, como o OpenCV
- O Hadoop é uma ferramenta que pode ajudar o processamento em paralelo de aplicações, mas ainda possui algumas limitações e funcionalidades extras podem ser necessárias para processar o resultado de saída do sistema (arquivo binário de saída com as imagens concatenadas)